

Lições de Teoria Ergódica, Processos Estocásticos e Sistemas Dinâmicos

Nelson Luís Dias

13 de março de 2014

Capítulo 1

Introdução

Em 1895, Osborne Reynolds publicou um artigo sobre escoamentos turbulentos no qual pela primeira vez aparece o que hoje denominamos decomposição de Reynolds: o campo de velocidade $\mathbf{U} = U_i \mathbf{e}_i$ de um fluido foi decomposto em $U_i = \langle U_i \rangle + u_i$ (“média” e “flutuação”), e equações para as médias $\langle U_i \rangle$, e para o segundo momento $\langle u_i u_i \rangle / 2$, foram deduzidas a partir de promediações das equações de Navier-Stokes para U_i (a velocidade do fluido no ponto $\mathbf{x} = x_i \mathbf{e}_i$, e no instante t).

Reynolds deu à promediação ‘ $\langle \cdot \rangle$ ’ que ele usou o significado de uma média espacial, num procedimento claramente inspirado pelo trabalho anterior, e pioneiro, de Maxwell sobre a teoria cinética dos gases (Maxwell, 1867).

Logo, percebeu-se que a dedução das equações para os momentos de ordem 1 e 2 (as equações de Reynolds) a partir das equações de Navier-Stokes requeria um conjunto de postulados, *que não aparece explicitamente no artigo de 1895*:

$$\langle u_i \rangle = 0, \quad (1.1)$$

$$\langle \langle U_i \rangle \rangle = 0, \quad (1.2)$$

$$\langle u_i \langle U_j \rangle \rangle = 0, \quad (1.3)$$

$$\left\langle \frac{\partial U_i}{\partial t} \right\rangle = \frac{\partial \langle U_i \rangle}{\partial t}, \quad (1.4)$$

$$\left\langle \frac{\partial U_i}{\partial x_j} \right\rangle = \frac{\partial \langle U_i \rangle}{\partial x_j}. \quad (1.5)$$

Os “postulados” (1.1)–(1.5) aparecem, de uma forma ou de outra, em todos os livros-texto importantes de turbulência. Por exemplo (e a lista não é abrangente): Hinze (1975), Tennekes e Lumley (1972), Monin e Yaglom (1975), Pope (2000).

O significado original da promediação de Reynolds não se manteve: a analogia entre o movimento das moléculas de um gás e o das partículas materiais de um fluido (debaixo da hipótese do contínuo) é essencialmente insustentável (Tennekes e Lumley, 1972, Capítulo 1).

Curiosamente, em nenhum caso os autores acima (ou quaisquer outros que sejam de nosso conhecimento) procuram deduzir matematicamente (1.1)–(1.5), com a possível exceção de Kundu (1990), que o faz para um *ensemble*, supostamente finito, de realizações do escoamento turbulento.

A definição mais comumente encontrada de ‘ $\langle \cdot \rangle$ ’, e que formalizaremos neste texto, é a de uma média probabilística (*ensemble average*), mas mesmo aqui uma definição precisa não pode ser facilmente encontrada na literatura de turbulência.

De qualquer forma, a abordagem estatística de sistemas complexos era promissora, e logo Reynolds recebeu a companhia ilustre de [Einstein \(1905\)](#) (movimento browniano), [Langevin \(1908\)](#) (idem), [Taylor \(1935a,b,c,d\)](#) (turbulência), e, naturalmente, [Kolmogorov \(1941\)](#) (turbulência).

Entretanto, o *significado* de se tomar médias probabilísticas sobre os resultados de um processo determinístico está longe de ser óbvio. Intuitivamente, a motivação é que o processo é suficientemente “complexo” (as velocidades das moléculas de um gás; um escoamento turbulento; o movimento browniano; etc.) para que seja mais fácil lidar apenas com médias e desvios-padrão, ou seja, *estatísticas*, e não com realizações, trajetórias, moléculas, partículas, etc., *individuais*. Ainda assim, do ponto de vista experimental, a tomada de médias sobre realizações é fortemente restrita pela disponibilidade de tais realizações. A saída é supor, debaixo de hipóteses adicionais tais como estacionariedade (mas que por si só não é suficiente), que médias tomadas sobre um número pequeno de realizações (tão pequeno quanto uma única) são capazes de estimar as médias de *ensemble*. Essa é a *hipótese ergódica*.

De todo modo, os procedimentos adotados pelos pioneiros eram necessariamente intuitivos, e tiveram que aguardar, como acontece tantas vezes na história da Física e da Matemática, por formalização posterior. A própria teoria de probabilidade só seria definitivamente formalizada por [Kolmogorov](#) em 1933; o teorema ergódico é devido a [Birkhoff \(1931\)](#), e a [von Neumann \(1932\)](#).

Finalmente, as conexões entre processos estocásticos e sistemas dinâmicos, que em última análise justificam o procedimento informal dos pioneiros, parecem ser ainda mais recentes (ver [Lebowitz e Penrose, 1973](#); [Collet, 2010](#)).

Neste texto, nós procuramos ao mesmo tempo traçar uma parte da história da abordagem estatística de sistemas dinâmicos, desde [Maxwell \(1867\)](#) até a atualidade, e prover um nível intermediário de formalização.

A formalização aqui não é feita no espírito de “arte pela arte”, mas sim no de embasar mais firmemente as análises de caráter probabilístico de sistemas físicos determinísticos, representados matematicamente por sistemas dinâmicos.

Capítulo 2

2014-02-19: Aditividade finita

Como conceitualizamos e formalizamos a propabilidade?

Existem várias abordagens possíveis:

1. Clássica (teórica ou “a priori”):

Consideramos um processo aleatório com n resultados igualmente prováveis, e um evento A que consiste em m desses resultados. A probabilidade desse evento é então definida por

$$P(A) \equiv \frac{m}{n}.$$

Crítica: no termo “igualmente prováveis”, já há a suposição de que nós “sabemos” o que é probabilidade antes de defini-la. Trata-se portanto de um argumento circular. (COMO PODEMOS MELHORAR ESSE TEXTO?)

2. Empírica (“a posteriori” ou frequentista):

Supõe-se que um determinado experimento é repetido n vezes “nas mesmas condições”. Se A é um evento identificável no experimento, a probabilidade de A é definida como o limite da razão entre número m de ocorrências de A e o número de repetições n quando $n \rightarrow \infty$:

$$P(A) \equiv \lim_{n \rightarrow \infty} \frac{m}{n}.$$

3. Subjetiva:

Aceita-se que podemos atribuir a diversos eventos uma “probabilidade” de ocorrência. Por exemplo, eu *acho* que a probabilidade de que eu encontre petróleo no terreno de minha casa é (ou deve ser) 10^{-12} .

4. Axiomática ([Kolmogorov, 1933](#)).

Uma tripla de propabilidade é uma tripla formada por (Ω, \mathcal{F}, P) , sendo Ω um conjunto não vazio, \mathcal{F} um campo sigma (uma σ -álgebra) de subconjuntos de Ω (PRECISAMOS USAR OS TERMOS CORRETOS), e P uma função, com

$$P : \mathcal{F} \rightarrow [0, 1],$$

$$A \in \mathcal{F} \mapsto P(A).$$

Axiomas:

$$P(A) \geq 0, \quad (2.1)$$

$$P(\Omega) = 1, \quad (2.2)$$

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i), \quad \text{se } A_i \cap A_j = \emptyset. \quad (2.3)$$

Os axiomas funcionam quando Ω é finito. Contudo, há conjuntos maiores/infinitos (?) para os quais a noção de probabilidade não faz sentido. Assim, uma σ -álgebra será um subconjunto de 2^Ω com uma certa estrutura, para o qual deverá fazer sentido especificar probabilidades.

Exemplo: Sabendo que $A_1 \cup A_2 \cup A_3 = (A_1 \cup A_2) \cup A_3$, prove por indução que o axioma (2.3) vale para todo n se ele valer para $n = 2$.

Para $n = 2$,

$$A_1 \cup A_2 = \emptyset \Rightarrow P(A_1 \cup A_2) = \sum_{i=1}^2 P(A_i). \quad (2.4)$$

Suponha agora que (2.3) valha para n , e que

$$A_{n+1} \cap \left[\bigcup_{i=1}^n A_i \right] = \emptyset, \quad i = 1, \dots, n.$$

Então,

$$P(A_1 \cup \dots \cup A_n \cup A_{n+1}) = P(B \cup A_{n+1}), \quad (2.5)$$

fazendo-se

$$B = \bigcup_{i=1}^n A_i.$$

A partir de (2.4),

$$P(B \cup A_{n+1}) = P(B) + P(A_{n+1}). \quad (2.6)$$

Por sua vez, como supusemos a validade de (2.3),

$$P(B) = P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i). \quad (2.7)$$

Logo,

$$P(A_1 \cup \dots \cup A_n \cup A_{n+1}) = P(A_{n+1}) + \sum_{i=1}^n P(A_i) = \sum_{i=1}^{n+1} P(A_i). \quad (2.8)$$

Note entretanto que, para que a prova seja válida, precisamos garantir que

$$A_{n+1} \cap \left[\bigcup_{i=1}^n A_i \right] = \emptyset \Rightarrow A_{n+1} \cap A_i = \emptyset, \forall i = 1, \dots, n.$$

Faça $C = A_{n+1}$, e considere a igualdade:

$$C \cap \left[\bigcup_{i=1}^n A_i \right] = \bigcup_{i=1}^n C \cap A_i. \quad (2.9)$$

Se ela for verdadeira, então:

$$\begin{aligned} A_{n+1} \cap \left[\bigcup_{i=1}^n A_i \right] = \emptyset &\Rightarrow \bigcup_{i=1}^n C \cap A_i = \emptyset \\ &\Rightarrow A_{n+1} \cap A_i = \emptyset, \quad \forall i = 1, \dots, n. \end{aligned}$$

Portanto, se (2.9) for verdadeira, a questão está liquidada.

De fato,

$$\begin{aligned} x \in C \cap \left[\bigcup_{i=1}^n A_i \right] &\Rightarrow (x \in C) \text{ e } \left(x \in \bigcup_{i=1}^n A_i \right), \\ &\Rightarrow \exists j \in \{1, \dots, n\} \mid (x \in C) \text{ e } (x \in A_j) \\ &\Rightarrow x \in C \cap A_j \\ &\Rightarrow x \in \bigcup_{i=1}^n C \cap A_i. \end{aligned}$$

Isso significa que

$$C \cap \left[\bigcup_{i=1}^n A_i \right] \subseteq \bigcup_{i=1}^n C \cap A_i.$$

Por outro lado,

$$\begin{aligned} x \in \bigcup_{i=1}^n C \cap A_i &\Rightarrow \exists j \mid x \in C \cap A_j \\ &\Rightarrow x \in C \cap \bigcup_{i=1}^n A_i. \end{aligned}$$

Isso significa que

$$\bigcup_{i=1}^n C \cap A_i \subseteq C \cap \left[\bigcup_{i=1}^n A_i \right].$$

Com isso, (2.9) está provada, e chegamos ao fim (desta prova).

Notas de Aula Professor Paulo Cezar P. de Carvalho - Ailin

Modelos elementares

$\Omega = \{\omega_1, \dots, \omega_n\} \rightarrow$ espaço amostral

$\mathcal{F} = 2^\Omega$ é o conjunto potência e inclui todos os subconjuntos de Ω , e, em particular, inclui $\{\omega_1\}, \{\dots\}, \{\omega_n\}$, os quais são chamados eventos complementares.

$$P(\{\omega_i\}) = P_i \in [0, 1] \mid \sum_{i=1}^n P_i = 1 \quad (2.10)$$

Caso equiprovável: $P_i = 1/n, \forall i \in \{1, \dots, n\}$.

Exemplo: 3 moedas são lançadas. Qual a probabilidade de saírem 2 caras?

Como defino Ω ? Se considerarmos $\Omega = \{0, 1, 2, 3\}$, as probabilidades são $1/8$ para 0 e 3, e $3/8$ para 1 e 2. Para $i = 0, 1, 2, 3$, temos

$$P(i) = \left(\frac{1}{8}\right)^i \left(1 - \frac{1}{8}\right)^{3-i} \binom{3}{i}, \quad (2.11)$$

distribuição binomial herdada do modelo equiprovável.

Exemplo: Escolher um número no intervalo $[0, 1]$ tal que $P([a, b]) = b - a$ para qualquer intervalo $[a, b] \subset [0, 1]$.

$\Omega = [0, 1]$

A primeira tentativa seria atribuir $P(\{a\})$. Se for equiprovável com $P \neq 0$ já estaria em contradição com a aditividade.

Com um conjunto enumerável (infinito) não é possível ter equiprobabilidade nem atribuindo probabilidade nula, porque não conseguiremos que a “soma” das $P(\{\})$ seja 1.

Capítulo 3

2014-02-24: Aditividade infinita

(Ou σ -Aditividade)

Passamos agora para casos em que o espaço amostral Ω deixa de ser um conjunto finito. Um conjunto infinito pode ser enumerável ou não-enumerável. Um conjunto enumerável é um conjunto cujos elementos possam ser colocados em uma relação biunívoca com os naturais. Os racionais são um conjunto enumerável (Cantor). Os números reais no intervalo fechado $[0, 1]$ são um conjunto não-enumerável.

Quando Ω é finito, todos os elementos de 2^Ω são eventos: a todos e a cada um deles pode ser atribuída uma probabilidade, e os axiomas (2.1)–(2.3) se aplicam.

Antes de seguir para o infinito, considere o exemplo: n lançamentos de uma moeda, cujos resultados individuais podem ser “cara” (0) ou “coroa” (1). Os eventos elementares com os quais podemos construir um espaço amostral são n -uplas do tipo

$$\begin{aligned} &(0, 0, \dots, 0, 0) \\ &(0, 0, \dots, 0, 1) \\ &(0, 0, \dots, 1, 0) \\ &\vdots \\ &(1, 1, \dots, 1, 1). \end{aligned}$$

Existem 2^n casos.

Suponha por exemplo que desejemos calcular a probabilidade de que ocorram k caras (e, consequentemente, $n - k$ coroas). Um evento deste tipo (exatamente k caras e $n - k$ coroas) pode ocorrer de $n!$ maneiras. No entanto, a posição das k caras é imaterial: todos os $k!$ casos aparecem da mesma forma. Idem para os $(n - k)!$ casos de permuta das posições das coroas. Concluimos que há

$$\binom{n}{k} = \frac{n!}{k!(n - k)!}$$

possibilidades de ocorrência de k caras. A sua probabilidade é

$$\frac{\binom{n}{k}}{2^n} = \binom{n}{k} \left(\frac{1}{2}\right)^k \left(\frac{1}{2}\right)^{n-k}.$$

Isso é um caso particular da distribuição binomial. Se 0 tem probabilidade p , e 1 tem probabilidade $1 - p$, a probabilidade de k zeros em n lançamentos é

$$P(k) = \binom{n}{k} p^k (1 - p)^{n-k}.$$

Exercício: Mostre que

$$\sum_{k=0}^n P(k) = 1.$$

Prova:

$$\begin{aligned}(p + (1 - p))^n &= 1 \\ &= \sum_{k=0}^n \binom{n}{k} p^k (1 - p)^{n-k} \\ &= \sum_{k=0}^n P(k).\end{aligned}$$

Agora, se $\Omega = \{x_1, x_2, x_3, \dots\}$ for enumerável, precisamos de

$$\sum_{i=1}^n P(x_i) = 1$$

e fica evidente que os $P(x_i)$ não podem ser todos iguais. Entretanto, ainda é possível aproveitar os x_i 's desde que a soma acima funcione.

Exemplo: Em um jogo, dez bolas numeradas de 0 a 9 podem ser sorteadas. Cada jogador sorteia uma bola, mostra o resultado e retorna a bola. Ganha o primeiro jogador que sortear um 7. O jogo poderia durar para sempre?

Nossa opção para construção do espaço amostral é

$$\Omega = \{0, 1, 2, 3, 4, \dots\}$$

0 significa que o 7 *nunca* é sorteado; 1 significa que o 7 foi sorteado na primeira rodada; 2 na segunda; e assim por diante. As probabilidades desses eventos não são iguais:

$$\begin{aligned}P(0) &= ?, \\ P(1) &= \frac{1}{10}, \\ P(2) &= \frac{9}{10} \times \frac{1}{10}, \\ P(3) &= \frac{9}{10} \times \frac{9}{10} \times \frac{1}{10}, \\ &\vdots \\ P(n) &= \left(\frac{9}{10}\right)^{n-1} \times \frac{1}{10}\end{aligned}$$

É elementar verificar que $P(n)$, $n \geq 1$, é uma série geométrica com soma 1. Portanto, o evento “o 7 nunca é sorteado”, indicado por 0, tem probabilidade complementar à $P(1) + P(2) + \dots = 1$, e sua probabilidade é zero.

Finalmente, considere o caso em que desejamos atribuir probabilidades dentro do conjunto não-enumerável $\Omega = [0, 1]$. Note que faz sentido atribuir probabilidade zero a um ponto qualquer:

$$P(X = a) = 0$$

e que é muito razoável atribuir probabilidades a intervalos:

$$P([a, b]) = b - a.$$

O problema é que se A é um evento, o seu complemento \overline{A} também tem que ser, com $P(\overline{A}) = 1 - P(A)$, pela propriedade de aditividade finita (2.3). Portanto, se $(a, b] \in \mathcal{F}$, devemos também ter $\overline{(a, b]} \in \mathcal{F}$, onde \mathcal{F} será a classe dos eventos cujas probabilidades podem ser quantificadas.

Entretanto, o complemento de um único intervalo $(a, b]$ *não* é um único intervalo. Desconfiamos que uma criatura desse tipo, $[0, a] \cup (b, 1]$, precisa ser definida com as mesmas propriedades genéricas de $(a, b]$, de forma que ambos pertençam a \mathcal{F} . O caminho para \mathcal{F} , entretanto, é longo.

Uma extensão do que vimos para a binomial é a distribuição multinomial:

$$1 = (p_1 + \dots + p_n)^n = \sum_{l_1 + \dots + l_k = n} \binom{n}{l_1 \dots l_k} p_1^{l_1} \dots p_k^{l_k},$$

$$\binom{n}{l_1 \dots l_k} = \frac{n!}{l_1! \dots l_k!}.$$

Capítulo 4

2014-02-26: Semi-anéis, anéis, e outros bichos

Definição

Uma classe \mathcal{S} de conjuntos é um *semi-anel* quando:

$$\begin{aligned}\emptyset &\in \mathcal{S}, \\ A, B \in \mathcal{S} &\Rightarrow A \cap B \in \mathcal{S}, \\ A, B \in \mathcal{S} &\Rightarrow A - B = A \cap \overline{B} = \bigsqcup_{i=1}^n E_i,\end{aligned}$$

onde $E_i \in \mathcal{S}$. O símbolo \bigsqcup significa “uniões disjuntas”.

Seja \mathcal{S} a classe formada por *intervalos* do tipo

$$(a, b] \quad \text{ou} \quad \emptyset.$$

1. $\emptyset \in \mathcal{S}$? Sim.
2. A interseção de dois elementos de \mathcal{S} pertence a \mathcal{S} ?

Sim: as possibilidades para interseção de $(a, b]$ com $(c, d]$ são

$$\begin{aligned}\emptyset &\in \mathcal{S}, \\ (c, b] &\in \mathcal{S}, \\ (c, d] &\in \mathcal{S}, \\ (a, d] &\in \mathcal{S}, \\ (a, b] &\in \mathcal{S}.\end{aligned}$$

Talvez seja possível resumir:

$$(a, b] \cap (c, d] = (\max(a, c), \min(b, d)) \quad \text{ou} \quad \emptyset?$$

3. $A - B$ (A, B intervalos) é exprimível como uma união finita disjunta de intervalos?

Sim:

$$\begin{aligned}(a, b] \cap \overline{(c, d]} &= (a, b] \cap [(0, c] \cup (d, 1]] \\ &= \underbrace{(a, b] \cap (0, c]}_{\in \mathcal{S}} \cup \underbrace{(a, b] \cap (d, 1]}_{\in \mathcal{S}} \quad \blacksquare\end{aligned}$$

Portanto, essa classe \mathcal{S} de intervalos é um semi-anel.

Definição:

$\mathcal{R} \subset 2^\Omega$ é um *anel* quando:

$$\begin{aligned}\emptyset &\in \mathcal{R}, \\ A, B \in \mathcal{R} &\Rightarrow A \cap B \in \mathcal{R}, \\ A, B \in \mathcal{R} &\Rightarrow A \Delta B \in \mathcal{R}.\end{aligned}$$

Lembre-se:

$$A \Delta B \equiv (A - B) \cup (B - A).$$

Tivemos uma discussão sobre o motivo de se usar a diferença simétrica nessas definições: alguém gostaria de resumir a discussão em L^AT_EX?

Anéis triviais são:

$$\{\emptyset, \Omega\} \quad \text{e} \quad 2^\Omega.$$

É possível mostrar as seguintes propriedades de anéis: se $A, B \in \mathcal{R}$, então:

$$\begin{aligned}A \cap B &\in \mathcal{R}, \\ A \Delta B &\in \mathcal{R}, \\ A \cup B &\in \mathcal{R}, \\ A - B &\in \mathcal{R}, \\ B - A &\in \mathcal{R}, \\ \emptyset &\in \mathcal{R}.\end{aligned}$$

Mas a última não faz parte da *definição* de \mathcal{R} ????

Note também que o complemento ainda não apareceu na jogada.

Teorema

A partir de um semi-anel \mathcal{S} é possível construir um anel \mathcal{R} por meio somente de uniões disjuntas finitas de elementos de \mathcal{S} , ou seja:

$$\mathcal{R} = \left\{ \bigcup_{i=1}^n A_i \right\}, \quad A_i \in \mathcal{S}.$$

Definição

Uma *álgebra* ou um *campo* \mathcal{A} é um anel que contém Ω . Segue-se imediatamente que

$$A \in \mathcal{A} \Rightarrow \overline{A} \in \mathcal{A}.$$

Definição Um σ -anel é um anel fechado por uma união enumerável

Comentário: “fechado” significa que uniões enumeráveis de elementos do σ - \mathcal{R} ainda pertencem a ele.

Segue-se imediatamente que o σ - \mathcal{R} também é fechado por interseções enumeráveis.

Definição Uma σ -álgebra ou σ -campo ou campo de Borel é uma álgebra fechada por uniões enumeráveis.

Segue-se imediatamente que uma σ -álgebra também é fechada por interseções enumeráveis.

Definição Dada uma classe $\mathcal{C} \subseteq 2^\Omega$, uma sequência monótona de elementos $E_i \in \mathcal{C}$, $i \in \mathbb{N}$, é definida por

$$E_i \subseteq E_{i+1}$$

ou

$$E_i \supseteq E_{i+1}.$$

Definição Uma classe \mathcal{M} é dita *monótona* quando todas as suas sequências monótonas atendem a:

$$E_i \subseteq E_{i+1} \Rightarrow \bigcup_{i=1}^n E_i \in \mathcal{M},$$

ou

$$E_i \supseteq E_{i+1} \Rightarrow \bigcap_{i=1}^n E_i \in \mathcal{M}.$$

A questão agora é como construir σ -álgebras a partir de álgebras, anéis ou semi-anéis.

Teorema: Para as famílias \mathcal{R} , \mathcal{A} , $\sigma\text{-}\mathcal{R}$, $\sigma\text{-}\mathcal{A}$, \mathcal{M} de anéis, álgebras, sigma-anéis, sigma-álgebras, e classes monótonas \mathcal{M} , interseções arbitrárias produzem famílias de mesmo tipo.

Em resumo: se \mathcal{F}_i , $i \in I$, são classes de algum dos tipos acima, então

$$\bigcap_{i \in I} \mathcal{F}_i$$

também é.

Por exemplo: se

$$\mathcal{F}_i, i \in I$$

são σ -álgebras, então

$$\bigcap_{i \in I} \mathcal{F}_i$$

também é uma σ -álgebra.

4.1 Geração de σ -álgebras

Seja \mathcal{S} um semi-anel que gera o anel \mathcal{R} . A *menor* σ -álgebra contendo \mathcal{S} ou gerada por \mathcal{R} é denominada “ σ -álgebra de Borel” \mathcal{B} .

No caso de $\Omega = [0, 1]$, a σ -álgebra de Borel é a menor σ -álgebra que contém os intervalos $(a, b]$.

Para ela, é possível definir uma medida de probabilidade

$$\begin{aligned} P : \mathcal{B} &\rightarrow [0, 1], \\ A \in \mathcal{B} &\mapsto P(A) \in [0, 1], \end{aligned}$$

de tal forma que

$$\begin{aligned}P(\emptyset) &= 0, \\P(\Omega) &= 1, \\P\left(\bigsqcup_{i=1}^{\infty} A_i\right) &= \sum_{i=1}^{\infty} P(A_i).\end{aligned}$$

Capítulo 5

2014-03-10: Existe um conjunto não-mensurável em $(0, 1]$

Uma nova operação será usada *ad nauseam* nesta lição. Para $x, y \in (0, 1]$:

$$x \boxplus y \equiv \begin{cases} x + y, & x + y \leq 1, \\ x + y - 1, & x + y > 1. \end{cases} \quad (5.1)$$

Seguem-se imediatamente os seguintes fatos: para $x, y, z \in (0, 1]$,

$$x \boxplus y = y \boxplus x, \quad (5.2)$$

$$z = x \boxplus y \Leftrightarrow \exists r \in (-1, +1] : z = x + r. \quad (5.3)$$

Agora, para *qualquer* subconjunto E de $(0, 1]$, defina um novo conjunto $E(x)$

$$E(x) \equiv \{x \boxplus y, y \in E\}. \quad (5.4)$$

$E(x)$ é a *translação* (de uma distância x) do conjunto E .

Dúvida: $E \subseteq (0, 1]$ ou $E \in \mathcal{B}$?

Dúvida: “translação *em* x ” me soa estranho, pois todo $y \in E$ é transladado *de* x .

Suponha que exista uma coisa tal como uma medida “natural” em $(0, 1]$. Para o intervalo $(a, b]$ essa medida é

$$|(a, b]| \equiv b - a. \quad (5.5)$$

Vamos supor, sem entrar em muitos detalhes, que para todo $B \in \mathcal{B}$, existe uma $|B|$ compatível com (5.5), *i.e.*, redutível a (5.5) se B for um intervalo.

A notação $E(x)$ é a usada por [Taylor \(1973\)](#).

Agora, se $E \in \mathcal{B}$, então,

$$|E(x)| = |E|. \quad (5.6)$$

Agora, como sempre, \mathbb{Q} é o conjunto dos racionais. Esse conjunto é enumerável. Consideremos os racionais contidos em $(0, 1]$. Esse segundo conjunto é

$$Q \equiv \mathbb{Q} \cap (0, 1]. \quad (5.7)$$

Valeria a pena provar que

Q é enumerável.

Com essas definições à mão, estudemos então as propriedades dos conjuntos do tipo $Q(x)$.

1.

$$x \in (0, 1] \Rightarrow x \in Q(x). \quad (5.8)$$

Será verdade? Como provar?

$$Q(x) = \{x \boxplus y, y \in Q\}$$

Se 0 pertencesse a Q , (5.8) seria trivial. Mas é quase, porque $1 \in Q$. Faça $y = 1$ acima; então,

$$x = x + 1 - 1 = x \boxplus 1 \in Q(x) \blacksquare$$

2.

$$x \in Q \Rightarrow Q(x) = Q. \quad (5.9)$$

De fato: para começar, $x, y \in Q \Rightarrow x \boxplus y \in Q$. De fato, $x \boxplus y \in (0, 1]$, e tanto $x + y$ quanto $x + y - 1$, conforme for o caso, são números racionais em $(0, 1]$. Isso basta!, pois, *neste caso*, $Q(x) = \{x \boxplus y, y \in Q\} = Q \blacksquare$

3.

$$x_1 - x_2 \notin \mathbb{Q} \Rightarrow Q(x_1) \cap Q(x_2) = \emptyset, \quad (5.10)$$

$$x_1 - x_2 \in \mathbb{Q} \Rightarrow Q(x_1) = Q(x_2). \quad (5.11)$$

Dessa forma, os conjuntos $\{Q(x), x \in (0, 1]\}$ (que constituem uma *classe*, ou *família*) particionam o intervalo $(0, 1]$ em subconjuntos disjuntos cuja união é o próprio $(0, 1]$. Há bastante material aqui. Antes das deduções, vamos escrever formalmente essa última observação:

$$\bigcup_{x \in (0, 1]} Q(x) = (0, 1].$$

Note também que os índices na expressão acima são demasiados, devido a (5.11). Queremos chegar a uma afirmação mais econômica:

$$\bigsqcup_{x \in T} Q(x) = (0, 1]$$

(note a disjunção). Na sequência, precisamos provar (5.10)–(5.11) e prosseguir na obtenção do conjunto T . Esse último se revelará um conjunto interessante, e na verdade o ponto final desta lição: T se revelará um conjunto *não mensurável*.

Para provar (5.10): Vamos tentar *reductio ad absurdum*. Seja $z \in Q(x_1)$ e $z \in Q(x_2)$: nesse caso, a interseção $Q(x_1) \cap Q(x_2)$ não seria o conjunto vazio. Porém, debaixo dessa hipótese:

$$z = x_1 \boxplus y, y \in Q,$$

$$z = x_2 \boxplus y, y \in Q.$$

Agora,

$$\begin{aligned}(x_1 \boxplus y) - (x_2 \boxplus y) &= x_1 - x_2, \text{ ou} \\ &= x_1 - x_2 - 1 \text{ ou} \\ &= x_1 - x_2 + 1.\end{aligned}$$

Portanto, subtraindo (dessa forma) as duas expressões acima,

$$(-1 \text{ ou } 0 \text{ ou } +1) = x_1 - x_2.$$

mas $(-1, 0, +1)$ são racionais, o que contraria a hipótese original sobre $x_1 - x_2$ ■

Para provar (5.11): Volte acima e escreva a expressão geral:

$$(x_1 \boxplus y) - (x_2 \boxplus y) = x_1 - x_2 + s,$$

onde, como vimos, ou $s = 0$ ou $s = -1$ ou $s = +1$. Reescreva:

$$x_1 \boxplus y = x_2 \boxplus y + (x_1 - x_2) + s.$$

Note agora que é *sempre* possível escrever $x_2 \boxplus y = x_2 + r$ (veja (5.3)), onde *agora* r é racional, e não necessariamente está em Q . Substitua:

$$x_1 \boxplus y = x_2 + r + s + (x_1 - x_2).$$

O lado esquerdo é um número em Q . Portanto, o lado direito é um número em Q :

$$x_2 + p \in Q, \tag{5.12}$$

onde $p = (r + s + (x_1 - x_2))$ e portanto $p \in \mathbb{Q}$ (mas não necessariamente $p \in Q$). Agora, utilizando (5.3), vemos que é possível escrever o lado direito como $x_2 \boxplus z$, onde $z \in Q$. Disso se segue que

$$\{x_1 \boxplus y, y \in Q\} = \{x_2 \boxplus z, z \in Q\}$$

e portanto $Q(x_1) = Q(x_2)$ ■

Relembrando:

$$x \in Q \Rightarrow Q(x) = Q$$

significa, por exemplo:

$$Q(1/2) = Q(1/3) = Q(1).$$

$$x_1 - x_2 \in \mathbb{I} \Rightarrow Q(x_1) \cap Q(x_2) = \emptyset$$

significa, por exemplo:

$$Q(\sqrt{3}/2) \cap Q(3/2) = \emptyset.$$

$$x_1 - x_2 \in \mathbb{Q} \Rightarrow Q(x_1) = Q(x_2)$$

significa, por exemplo:

$$Q(\sqrt{2}/1000 + 1/8) = Q(\sqrt{2}/1000 + 3/8)$$

Ou seja: as criaturas estão ficando estranhas.

Para fechar esta parte bastante cansativa para a mente:

$$\bigcup_{x \in (0,1]} Q(x) = (0, 1]$$

pois $x \in Q(x)$.

5.1 O axioma da seleção e um conjunto estranho

Seja \mathcal{C} a família dos conjuntos $Q(x)$, $x \in (0, 1]$. Escolha um único ponto em $(0, 1]$ pertencente a cada $Q(x)$. O conjunto dos pontos assim escolhidos será chamado T , e temos que $T \subset (0, 1]$. O que fizemos significa que, *por definição*, não há dois pontos em T pertencentes ao mesmo $Q(x)$. Segue-se que

$$\bigsqcup_{t \in T} Q(t) = (0, 1].$$

Estudemos as propriedades dos conjuntos $T(r_i), r_i \in Q$.

1.

$$\bigcup_{i=1}^{\infty} T(r_i) = (0, 1]. \quad (5.13)$$

Só precisamos provar que, se $x \in (0, 1]$, $\exists i \in \mathbb{N} : x \in T(r_i)$. Mas, de (5.8), segue-se que $x \in (0, 1] \Rightarrow x \in Q(x)$. Agora, portanto, se $x \in Q(x)$, escolha $t \in Q(x)$, onde t é o representante de $Q(x)$: $t \in T$.

Veja:

$$\begin{aligned} Q(x) &= x \boxplus y, \quad y \in Q, \\ t \in Q(x) &\Rightarrow t = x \boxplus y \text{ para algum } y \in Q. \end{aligned}$$

Logo, de (5.3), existe algum $q \in Q$ tal que $t = x + q$; pelo mesmo motivo agora deve existir algum $r \in Q$ tal que $x = t + r$. Mas Q é enumerável (não provamos!), portanto existe um índice i tal que $x = t + r_i$, $i \in \mathbb{N}$, e $Q = \bigsqcup_{i=1}^{\infty} r_i$. Logo, $x \in T(r_i)$. A união dos $T(r_i)$ gera o $(0, 1]$.

2. Os $T(r_i)$ são disjuntos. Lembre-se de que T contém um único representante de cada $Q(x)$. Se houvesse $r_i \neq r_j$ com $y \in [T(r_i) \cap T(r_j)]$, então teríamos

$$\begin{aligned} y &= t_i \boxplus r_i & \text{e} \\ y &= t_j \boxplus r_j. \end{aligned}$$

“Subtraia”:

$$0 = (t_i - t_j) + q$$

onde q é racional (novamente, nós usamos (5.3)). Logo, $t_i - t_j$ é racional, donde $Q(t_i) = Q(t_j)$ (devido a (5.11)). Mas isso não é possível, porque $Q(t_i)$ possui um único representante em T . Portanto, a disjunção dos $T(r_i)$'s transforma (5.13) em

$$\bigsqcup_{i=1}^{\infty} T(r_i) = (0, 1]. \quad (5.14)$$

Finalmente: se T fosse mensurável, haveria $|T| = |T(r_i)|$ para todo i . Agora, pela sigma-aditividade:

$$\sum_{i=1}^{\infty} |T(r_i)| = |(0, 1]| = 1.$$

Isso, nós também já vimos em outra lição, é impossível. T não pode ser mensurável ■

Capítulo 6

2014-03-12: Teoria de probabilidade e incursões na física e em geociências

6.1 Variável aleatória

Em uma visão moderna de probabilidades e estatística, inventada por Kolmogorov, nós precisamos de:

1. um conjunto Ω — responsável por “sorteios”, denominado *Espaço Amostral*;
2. Uma função

$$\begin{aligned} X : \Omega &\rightarrow \mathbb{R} \\ \omega \in \Omega &\mapsto x = X(\omega) \end{aligned}$$

A função X é denominada “variável aleatória”. A função X tem que ser *mensurável*, e nós vamos gastar algum tempo com isso ainda mais à frente.

3. Uma função

$$\begin{aligned} P : \mathcal{F} &\rightarrow [0, 1] \\ A \in \mathcal{F} &\mapsto P(A) \end{aligned}$$

O conjunto \mathcal{F} é uma *classe* (um conjunto de conjuntos). Como vimos no capítulo 3, \mathcal{F} é uma σ -álgebra. Cada *elemento* de \mathcal{F} é um sub-conjunto mensurável $A \in \Omega$, ao qual nós associamos um número $P(A)$. Os elementos de \mathcal{F} gozam de algumas propriedades importantes em teoria de probabilidades:

$$A \in \mathcal{F} \Rightarrow \bar{A} \in \mathcal{F} \tag{6.1}$$

$$A, B \in \mathcal{F} \Rightarrow A \cup B \in \mathcal{F} \tag{6.2}$$

$$A, B \in \mathcal{F} \Rightarrow A \cap B \in \mathcal{F} \tag{6.3}$$

$$\emptyset \in \mathcal{F} \tag{6.4}$$

$$\Omega \in \mathcal{F} \tag{6.5}$$

Nós podemos reconhecer nestas propriedades, imediatamente, que os sub-conjuntos $A \in \Omega$ são *eventos*. A função P associa a cada evento uma *probabilidade*. A função P também




Figura 6.1: Representação gráfica do evento $X(\omega) \leq x$

deve obedecer a algumas regras. Se A_1, \dots, A_n são conjuntos *disjuntos*, $A_i \cap A_j = \emptyset$, $i \neq j$, então

$$P(A_i) \geq 0 \quad (6.6)$$

$$P(\Omega) = 1 \quad (6.7)$$

$$P(A_i \cup A_j) = P(A_i) + P(A_j) \quad (6.8)$$

Esta última é um caso particular da σ -aditividade:

$$P\left(\bigsqcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i). \quad (6.9)$$

É muito importante enfatizar que o espaço amostral é um conceito *abstrato*: ele ajuda a conceituar probabilidades e também ajuda a demonstrar alguns resultados, mas na prática tudo o que vemos no mundo “real”, ou seja, os únicos objetos que podemos manipular em aplicações de teoria de probabilidade, são as *realizações* da variável aleatória: $x = X(\omega)$.

Para avaliar a probabilidade de ocorrência de certos níveis de uma variável aleatória nós usamos eventos do tipo $X(\omega) \leq x$, que pode ser entendido com o auxílio da figura 6.1.

Diferentes maneiras de escrever o evento A são:

$$A = \{\omega \mid X(\omega) \leq x\},$$

$$A = \{X(\omega) \leq x\},$$

$$A = \{X \leq x\}.$$

Note que na última forma desapareceu qualquer referência explícita ao espaço amostral.

Nós agora vamos definir a função distribuição acumulada (FDA) de probabilidade de uma variável aleatória X :

$$F_X(x) \equiv P(\{X \leq x\}). \quad (6.10)$$

A notação da equação (6.10) é normalmente simplificada para $F_X(x) \equiv P\{X \leq x\}$. A FDA nos permite calcular facilmente probabilidade relacionadas a X . Por exemplo, para obter a probabilidade de que X ocorra em um intervalo $[a, b]$:

$$P\{a \leq X \leq b\} = P\{X \leq b\} - P\{X \leq a\} \quad (6.11)$$

$$= F(b) - F(a). \quad (6.12)$$

As propriedades da função distribuição acumulada são:

$$F(-\infty) = 0, \quad (6.13)$$

$$F(+\infty) = 1, \quad (6.14)$$

$$F(b) - F(a) \geq 0, \text{ para } a < b. \quad (6.15)$$

A função densidade de probabilidade (FDP), f_X , é

$$f_X(x) \equiv \frac{dF_X}{dx}, \quad (6.16)$$

com $f_X(x) \geq 0$ e

$$\int_{-\infty}^{+\infty} f_X(x) dx = 1. \quad (6.17)$$

6.2 Média e momentos

A média de uma variável aleatória, ou valor esperado de uma variável aleatória, é

$$\langle X \rangle \equiv \int_{-\infty}^{+\infty} x f_X(x) dx. \quad (6.18)$$

De maneira mais geral, seja $y = q(x)$ uma função de x ; então para cada sorteio de X corresponderá um $Y = q(X)$, ou seja: Y será (também) uma variável aleatória. A média de Y será dada por

$$\langle Y \rangle = \langle q(X) \rangle = \int_{-\infty}^{+\infty} q(x) f_X(x) dx. \quad (6.19)$$

Momentos centrais desempenham um papel importante em Teoria de Probabilidade. A definição do momento central de ordem n é

$$c_{Xn} \equiv \langle (x - \langle X \rangle)^n \rangle = \int_{-\infty}^{+\infty} (x - \langle X \rangle)^n f_X(x) dx. \quad (6.20)$$

6.3 Distribuições conjuntas

Para definirmos distribuições conjuntas de probabilidade, precisamos estender as definições da seção 6.1.

No \mathbb{R}^2 , uma variável aleatória é uma função $\mathbf{X} = (X, Y)$ função de $\omega \in \Omega$:

$$\begin{aligned}\mathbf{X} : \Omega &\rightarrow \mathbb{R}^2, \\ \omega &\mapsto \mathbf{x} = \mathbf{X}(\omega).\end{aligned}$$

A função densidade acumulada conjunta será

$$F_{X,Y}(x, y) \equiv P\{X \leq x \wedge Y \leq y\}, \quad (6.21)$$

e a função densidade de probabilidade será

$$f_{X,Y}(x, y) \equiv \frac{\partial^2 F_{X,Y}}{\partial x \partial y} = \frac{\partial^2 F_{X,Y}}{\partial y \partial x}. \quad (6.22)$$

As funções densidade de probabilidade *marginais* são

$$f_X(x) \equiv \int_{y=-\infty}^{+\infty} f_{X,Y}(x, y) \, dy, \quad (6.23)$$

$$f_Y(y) \equiv \int_{x=-\infty}^{+\infty} f_{X,Y}(x, y) \, dx. \quad (6.24)$$

Naturalmente,

$$\iint_{x,y} f_{X,Y}(x, y) \, dx \, dy = 1. \quad (6.25)$$

O *valor esperado* de uma função de X e Y é

$$\langle g(X, Y) \rangle = \iint_{x,y} g(x, y) f_{X,Y}(x, y) \, dx \, dy. \quad (6.26)$$

Com os resultados acima, nós podemos agora deduzir o seguinte fato: se X e Y são duas variáveis aleatórias quaisquer,

$$\langle X + Y \rangle = \langle X \rangle + \langle Y \rangle. \quad (6.27)$$

a) *Insight* com matemática finita: seja (x_i, y_i) , $i = 0, \dots, n-1$ uma amostra qualquer de n pares de observações. Então, a *média amostral* da soma é

$$\begin{aligned}\overline{x+y} &= \frac{1}{n} \sum_{i=0}^{n-1} (x_i + y_i) \\ &= \frac{1}{n} \sum_{i=0}^{n-1} x_i + \frac{1}{n} \sum_{i=0}^{n-1} y_i \\ &= \bar{x} + \bar{y}.\end{aligned}$$

Note como não foi necessária nenhuma hipótese adicional sobre a natureza dos x 's e y 's ou sobre qualquer relação entre eles.

b) com Teoria de Probabilidade. Seja $g(x, y) = x + y$. Então,

$$\begin{aligned}
\langle g(X, Y) \rangle &= \langle X + Y \rangle = \iint_{x,y} (x + y) f_{X,Y}(x, y) \, dy \, dx \\
&= \iint_{x,y} x f_{X,Y}(x, y) \, dy \, dx + \iint_{x,y} y f_{X,Y}(x, y) \, dy \, dx \\
&= \iint_{x,y} x \underbrace{[f_{X,Y}(x, y) \, dy]}_{f_X(x)} \, dx + \iint_{x,y} y \underbrace{[f_{X,Y}(x, y) \, dx]}_{f_Y(y)} \, dy \\
&= \int_{-\infty}^{+\infty} x f_X(x) \, dx + \int_{-\infty}^{+\infty} y f_Y(y) \, dy \\
&= \langle X \rangle + \langle Y \rangle.
\end{aligned}$$

Já que estamos falando de distribuições conjuntas, devemos tocar no conceito fundamental de independência/dependência. Dados dois eventos A e B , a probabilidade de B condicionada a A é

$$P(B|A) \equiv \frac{P(A \cap B)}{P(A)} \quad (6.28)$$

Definição: B e A são independentes quando

$$P(B|A) = P(B). \quad (6.29)$$

Corolário: Se A e B são independentes,

$$P(B|A) = \frac{P(A \cap B)}{P(A)} = P(B) \Rightarrow P(A \cap B) = P(A)P(B). \quad (6.30)$$

Isso nos leva imediatamente à definição de independência de variáveis aleatórias: X e Y são independentes quando os *eventos*

$$A = \{\omega | X(\omega) \leq x\} \text{ e } B = \{\omega | Y(\omega) \leq y\}$$

são independentes, ou seja:

$$\begin{aligned}
P(A \cap B) &= P(A)P(B), \\
P(X(\omega) \leq x \wedge Y(\omega) \leq y) &= P(X(\omega) \leq x) P(Y(\omega) \leq y), \\
F_{X,Y}(x, y) &= F_X(x)F_Y(y).
\end{aligned}$$

Portanto, se X e Y são independentes, então a FDA conjunto é igual ao produto das FDA's marginais. Fazendo a 2ª derivada cruzada,

$$\begin{aligned}
f_{X,Y}(x, y) &= \frac{\partial^2 F_{X,Y}(x, y)}{\partial y \partial x} \\
&= \frac{\partial^2 F_X(x) F_Y(y)}{\partial y \partial x} \\
&= \frac{\partial}{\partial y} \left[\frac{\partial F_X}{\partial x} F_Y(y) \right] \\
&= f_X(x) \frac{\partial F_Y}{\partial y} \\
&= f_X(x) f_Y(y).
\end{aligned}$$

A próxima definição é a densidade de probabilidade de y *condicionada* à ocorrência de x :

$$f_{Y|x}(y) \equiv \frac{f_{X,Y}(x, y)}{f_X(x)}. \quad (6.31)$$

Embora deva ser possível deduzir rigorosamente (6.31) a partir de (6.28), não vou fazê-lo (ainda). Em vez disto, vou procurar um caso particular muito interessante. Primeiramente, note que, por definição, a densidade marginal de y é dada por

$$\begin{aligned} f_Y(y) &= \int_{x=-\infty}^{+\infty} f_{X,Y}(x, y) dx \\ &= \int_{x=-\infty}^{+\infty} f_{Y|x}(y) f_X(x) dx. \end{aligned} \quad (6.32)$$

Considere agora o caso em que $y = g(x)$, ou seja: em que Y está determinísticamente determinado a partir da observação de x . A função densidade de probabilidade condicionada é então, simplesmente,

$$f_{Y|x}(y) = \delta(g(x) - y), \quad (6.33)$$

ou seja: dado x , a probabilidade de que $Y = g(x)$ é 1 (note as letras maiúscula e minúscula). Note também que (6.33) é uma densidade de probabilidade legítima, já que sua integral em y é igual a 1. O primeiro resultado que vamos obter a partir daqui é uma fórmula para $f_Y(y)$:

$$\begin{aligned} f_Y(y) &= \int_{x=-\infty}^{+\infty} f_{Y|x}(y) f_X(x) dx \\ &= \int_{x=-\infty}^{+\infty} \delta(g(x) - y) f_X(x) dx. \end{aligned} \quad (6.34)$$

Essa é uma equação totalmente geral, que permite o cálculo da densidade de probabilidade de *qualquer* variável aleatória definida por uma função, $Y = g(X)$, independentemente de ela ser biunívoca ou não! A equação (6.34) pode ser prontamente generalizada para funções de várias variáveis. Em particular, se $Z = g(X, Y)$, tem-se

$$f_Z(z) = \int_{x=-\infty}^{+\infty} \int_{y=-\infty}^{+\infty} \delta(g(x, y) - z) f_{X,Y}(x, y) dy dx. \quad (6.35)$$

Considere agora o seguinte exemplo: $y = x^2$, $-1 \leq X \leq +1$, com $f_X(x) = 1/2$. Essa função *não* é biunívoca. A densidade de probabilidade de y é

$$f_Y(y) = \int_{-1}^{+1} \delta(x^2 - y) \frac{1}{2} dx. \quad (6.36)$$

Para calcular a integral acima, é preciso um pouco de cuidado. Primeiramente, note que

$$y = x^2 \Rightarrow x = \pm\sqrt{y} : \quad (6.37)$$

existem duas raízes, e isto precisa ser levado em consideração pelo ser humano que está resolvendo o problema: a fórmula (6.34) *em si* não vai dizer isso para você! O caminho mais rápido, aparentemente, é recorrer à seguinte propriedade da delta (Butkov, 1988, Cap. 6, p. 231):

$$\delta(x^2 - a^2) = (1/2a) [\delta(x + a) + \delta(x - a)] \quad (a > 0); \quad (6.38)$$

então,

$$f_Y(y) = \int_{-1}^{+1} \frac{1}{2\sqrt{y}} [\delta(x + \sqrt{y}) + \delta(x - \sqrt{y})] \frac{1}{2} dx = \frac{1}{4\sqrt{y}} [1 + 1] = \frac{1}{2\sqrt{y}} \blacksquare \quad (6.39)$$

Esse é um exemplo simples, porém muito rico. O valor esperado de Y , para o qual nós vamos usar a notação $\langle Y \rangle$, agora é facilmente obtido:

$$\langle Y \rangle = \int_0^1 y f_Y(y) dy = \int_0^1 y \frac{1}{2\sqrt{y}} dy = \int_0^1 \frac{\sqrt{y}}{2} dy = \frac{1}{3}, \quad (6.40)$$

enquanto que, devido à simetria de $f_X(x)$, $\langle X \rangle = 0$.

Mais interessante ainda é a seguinte questão: se X é a variável aleatória com distribuição uniforme entre $-1/2$ e $+1/2$, como acima, e $Y = X^2$, qual é a covariância entre X e Y ? Por definição, a covariância entre duas variáveis aleatórias é

$$\text{Cov}\{X, Y\} = \int_{x \in \mathbb{R}} \int_{y \in \mathbb{R}} (x - \langle X \rangle)(y - \langle Y \rangle) f_{X,Y}(x, y) dy dx. \quad (6.41)$$

Quando duas variáveis aleatórias são independentes, sua covariância é nula:

$$\begin{aligned} \text{Cov}\{X, Y\} &= \iint_{x \in \mathbb{R}, y \in \mathbb{R}} (x - \langle X \rangle)(y - \langle Y \rangle) f_{X,Y}(x, y) dy dx \\ &= \iint_{x \in \mathbb{R}, y \in \mathbb{R}} (x - \langle X \rangle)(y - \langle Y \rangle) f_X(x) f_Y(y) dy dx \\ &= \left[\int_{x \in \mathbb{R}} (x - \langle X \rangle) f_X(x) dx \right] \left[\int_{y \in \mathbb{R}} (y - \langle Y \rangle) f_Y(y) dy \right] \\ &= 0. \end{aligned}$$

No nosso caso particular, $y = x^2$, a covariância é

$$\begin{aligned} \text{Cov}\{X, Y\} &= \int_{x=-1}^1 \int_{y=0}^1 x(y - \frac{1}{3}) \delta(x^2 - y) f_X(x) dy dx \\ &= \int_{x=-1}^1 \int_{y=0}^1 x(x^2 - \frac{1}{3}) \delta(x^2 - y) \frac{1}{2} dy dx \\ &= \int_{x=-1}^1 x(x^2 - \frac{1}{3}) \int_{y=0}^1 \delta(x^2 - y) \frac{1}{2} dy dx \\ &= \frac{1}{2} \int_{x=-1}^1 x(x^2 - \frac{1}{3}) \underbrace{\int_{y=0}^1 [\delta(x^2 - y) dy]}_{=1} dx \\ &= \frac{1}{2} \int_{x=-1}^1 x(x^2 - \frac{1}{3}) dx = 0. \end{aligned} \quad (6.42)$$

Na linha acima de (6.42), note a utilização simultânea de duas propriedades da delta:

$$\int_{-\infty}^{+\infty} \delta(x - a) dx = 1, \quad (6.43)$$

$$\delta(x) = \delta(-x). \quad (6.44)$$

O resultado (6.42) é admirável: ele mostra que, mesmo que a dependência entre duas variáveis aleatórias seja *total*; mesmo que Y seja *totalmente* dependente de X na forma

$Y = g(X)$, é possível que $\text{Cov}\{X, Y\} = 0$. Moral da história: a covariância é uma medida de dependência *linear*, e *não* uma medida universal de dependência.

Além da covariância, é usual encontrar o coeficiente de correlação,

$$\varrho_{XY} = \frac{\text{Cov}\{X, Y\}}{[\text{Var}\{X\} \text{Var}\{Y\}]^{1/2}}.$$

Com a desigualdade de Schwarz,

$$-1 \leq \varrho_{XY} \leq +1$$

Considere agora o cálculo da função densidade de probabilidade da variável aleatória $Z = X + Y$, *soma* de duas variáveis aleatórias X e Y cuja distribuição conjunta de probabilidade, $f_{X,Y}(x, y)$, é conhecida. A função densidade de probabilidade de Z dada a ocorrência de x, y é

$$f_{Z|x,y} = \frac{f_{Z,X,Y}(z, x, y)}{f_{X,Y}(x, y)} = \delta(z - [x + y]) \quad (6.45)$$

Segue-se que a função densidade de probabilidade marginal de Z é

$$\begin{aligned} f_Z(z) &= \int_{x=-\infty}^{+\infty} \int_{y=-\infty}^{+\infty} f_{Z,X,Y}(z, x, y) \, dy \, dx \\ &= \int_{x=-\infty}^{+\infty} \int_{y=-\infty}^{+\infty} \delta(z - x - y) f_{X,Y}(x, y) \, dy \, dx \end{aligned} \quad (6.46)$$

Lembrando das propriedades da Delta de Dirac,

$$\int_{-\infty}^{+\infty} \delta(y - a) f(y) \, dy = f(a), \quad (6.47)$$

$$\delta(y - a) = \delta(a - y), \quad (6.48)$$

tem-se

$$f_Z(z) = \int_{x=-\infty}^{+\infty} f_{X,Y}(x, z - x) \, dx = \int_{y=-\infty}^{+\infty} f_{X,Y}(z - y, y) \, dy \quad \blacksquare \quad (6.49)$$

Finalmente, no caso de variáveis aleatórias X e Y independentes, as integrais acima tornam-se integrais de convolução:

$$f_Z(z) = \int_{x=-\infty}^{+\infty} f_X(x) f_Y(z - x) \, dx. \quad (6.50)$$

Note que esta é uma convolução no sentido da Teoria de Transformadas de Fourier, e não no sentido da Teoria de Transformadas de Laplace.

Quando, por outro lado, a relação $Y = g(X)$ é biunívoca, as coisas ficam mais fáceis:

$$\begin{aligned} P\{Y \leq y\} &= P\{X \leq x\}, \\ P\{Y \leq g(x)\} &= P\{X \leq x\}, \\ F_Y(g(x)) &= F_X(x), \\ \frac{d}{dx} F_Y(g(x)) &= \frac{d}{dx} F_X(x), \\ \frac{d}{dy} F_Y(g(x)) \frac{dg}{dx} &= f_X(x), \\ f_Y(y) \frac{dg}{dx} &= f_X(x). \end{aligned}$$

Mudando ligeiramente a notação, $y = y(x)$ produz

$$f_Y(y)dy = f_X(x)dx$$

cuja interpretação gráfica é óbvia.

Um caso particularmente útil e interessante é o de geração de uma variável aleatória no computador com uma distribuição dada. A resposta é o uso da própria FDA $F_X(x)$ no lugar de $g(x)$. Seja $U = F_X(X)$ a variável aleatória assim gerada. Nesse caso,

$$\begin{aligned} f_U(u)du &= f_X(x)dx, \\ f_U(u)\frac{du}{dx} &= f_X(x). \end{aligned}$$

mas

$$\frac{du}{dx} = \frac{dF_X(x)}{dx} = f_X(x);$$

portanto,

$$f_U(u) = 1, \quad 0 \leq u \leq 1. \quad (6.51)$$

A “receita” para gerar uma variável aleatória com FDA $F_x(x)$ é a seguinte:

a) gere uma variável u uniforme em $[0, 1]$.

b) calcule $x = F_X^{-1}(u)$.

Quando existe uma dependência linear, do tipo $Y = aX + b$, a *forma* da distribuição não muda:

$$\begin{aligned} x &= \frac{y - b}{a}, \\ \frac{dy}{dx} &= a, \\ f_Y(y)dy &= f_X(x)dx, \\ f_Y(y)\frac{dy}{dx} &= f_X(x), \\ f_Y(y)a &= f_X(x), \\ f_Y(y) &= \frac{1}{a}f_X\left(\frac{y - b}{a}\right). \end{aligned}$$

Seja Y o estimador de uma variável cujo valor verdadeiro (de população) é y . No caso mais geral,

$$\langle Y \rangle = y' \neq y. \quad (6.52)$$

A diferença entre o valor médio previsto pelo modelo (y') e o valor verdadeiro (y) é denominada o *viés* do modelo.

A figura 6.2 dá uma visão dessas relações.

Exemplo: soma de exponenciais




Figura 6.2: Relação entre as distribuições de probabilidade de X e Y quando a relação entre ambos é biunívoca.

Sejam

$$f_X(x) = \frac{1}{\beta} \exp\left(-\frac{x}{\beta}\right),$$

$$f_Y(y) = \frac{1}{\beta} \exp\left(-\frac{y}{\beta}\right),$$

ou seja: duas variáveis aleatórias X e Y independentes e igualmente distribuídas com distribuição exponencial. Se $Z = X + Y$,

$$\begin{aligned} P\{Z \leq z\} &= P\{X + Y \leq z\} \\ &= P\{(X, Y) \in \mathcal{D}\} \\ &= P(\mathcal{D}). \end{aligned}$$

Veja a figura [6.3](#)




Figura 6.3: Região de integração para cálculo da distribuição da soma de duas variáveis aleatórias exponenciais.

Agora,

$$\begin{aligned}
 P\{X + Y \leq z\} &= \int_{x=0}^z \int_{y=0}^{z-x} \frac{1}{\beta} \exp\left(-\frac{x}{\beta}\right) \frac{1}{\beta} \exp\left(-\frac{y}{\beta}\right) dy dx \\
 &= \int_{x=0}^z \exp\left(-\frac{x}{\beta}\right) \left[\int_{y=0}^{z-x} \exp\left(-\frac{y}{\beta}\right) d\left(\frac{y}{\beta}\right) \right] d\left(\frac{x}{\beta}\right) \\
 &= \int_{x=0}^z \exp\left(-\frac{x}{\beta}\right) \left[1 - \exp\left(-\frac{z-x}{\beta}\right) \right] d\left(\frac{x}{\beta}\right) \\
 &= \int_0^z \left(e^{-x/\beta} - e^{-z/\beta} \right) d\frac{x}{\beta} \\
 &= 1 - e^{-z/\beta} - \frac{z}{\beta} e^{-z/\beta}.
 \end{aligned}$$

Portanto,

$$\begin{aligned}
 F_Z(z) &= 1 - e^{-z/\beta} - \frac{z}{\beta} e^{-z/\beta}, \\
 f_Z(z) &= \frac{z}{\beta^2} e^{-z/\beta}.
 \end{aligned}$$

A fdp tem a forma de distribuição gama, cuja fórmula geral é

$$f_X(x) = \frac{1}{\beta \Gamma(\alpha)} \left(\frac{x}{\beta}\right)^{\alpha-1} e^{-\frac{x}{\beta}}. \quad (6.53)$$

Para $\alpha = 2$, $\Gamma(\alpha) = 1$, e a fórmula coincide. Esse é uma caso particular do seguinte resultado, mais geral:

$$X_1, \dots, X_n \sim \text{EXP}(\beta) \Rightarrow Z = \sum_{i=1}^n X_i \sim \text{GAMA}(n, \beta).$$

Capítulo 7

Modelos e erros

Exemplo 7.1 Seja M um modelo de previsão da temperatura da água de um rio. O modelo funciona de acordo com o seguinte esquema:

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \longrightarrow \boxed{M(\mathbf{x}; \boldsymbol{\theta})} \longrightarrow y' \neq y.$$

Aqui, o vetor $\mathbf{x} = (x_1, x_2, \dots, x_n)$ representa os *dados de entrada*; eles podem ser, por exemplo, a radiação solar incidente, a vazão do rio, a temperatura do ar, etc.. O modelo M em si é composto de elementos tais como a geometria rio (largura, profundidade, comprimento), pelas as equações utilizadas para calcular ou estimar a temperatura y , etc.. A *natureza* de M pode ser qualquer. Por exemplo, M pode ser simplesmente uma regressão linear múltipla

$$y = a_0 + a_1x_1 + a_2x_2 + \dots + a_nx_n \quad (7.1)$$

mas também pode ser um modelo físico de balanço de entalpia cuja incógnita seja a temperatura da água (Dias, 2003; Dias et al., 2003). Finalmente note que existe um vetor de *parâmetros* $\boldsymbol{\theta}$ de M . No caso da regressão múltipla (7.1), os parâmetros são a_0, a_1, \dots, a_n .

A partir do esquema geral representado pelo Exemplo 7.1, é fácil identificar que numerosos erros podem ocorrer no processo de modelagem. Em geral, nós classificamos os erros em 3 tipos

- A) Erro dos dados: os dados de entrada do modelo geralmente contêm erros. Só isto já faz com que os dados de entrada devam ser considerados como variáveis aleatórias X_1, X_2, \dots, X_n e consequentemente a saída do modelo, Y , também.
- B) Erro do modelo: todo modelo contém imperfeições e limitações, e muitas vezes é extremamente difícil até mesmo identificar inequivocamente um único modelo (por exemplo, é comum que diversas distribuições diferentes de probabilidade representem “igualmente bem” um determinado conjunto de observações).
- C) Erro dos parâmetros. Mesmo que o modelo seja perfeito, a aleatoriedade seja dos dados de entrada seja das próprias observações y nas quais nos baseamos para “calibrar” M — o processo de estimativa dos parâmetros $\boldsymbol{\theta}$ — faz com que estes últimos também carreguem incerteza.

Algumas estatísticas básicas de erros são definidas a seguir.

O vés do modelo é

$$v \equiv \langle Y \rangle - y = y' - y. \quad (7.2)$$

O erro médio quadrático do modelo é

$$\text{EMQ}\{Y\} \equiv \langle (Y - y)^2 \rangle \quad (7.3)$$

e sua raiz quadrada, que tem as mesmas dimensões de Y , é

$$\text{REMQ}\{Y\} = \sqrt{\text{EMQ}\{Y\}}. \quad (7.4)$$

A variância de Y é

$$\text{Var}\{Y\} = \langle (Y - \langle Y \rangle)^2 \rangle. \quad (7.5)$$

Muito importante: como em geral $\langle Y \rangle \neq y$, $\text{EMQ}\{Y\} \neq \text{Var}\{Y\}$. A relação entre ambas as estatísticas pode ser obtida muito facilmente:

$$\begin{aligned} \text{EMQ}\{Y\} &= \langle (Y - y)^2 \rangle \\ &= \langle [(Y - y') + (y' - y)]^2 \rangle \\ &= \langle (Y - y')^2 + 2(Y - y')(y' - y) + (y' - y)^2 \rangle \\ &= \langle (Y - y')^2 \rangle + 2(y' - y) \underbrace{\langle (Y - y') \rangle}_{=0} + \langle (y' - y)^2 \rangle \\ &= \text{Var}\{Y\} + v^2 \blacksquare \end{aligned} \quad (7.6)$$

Um bom modelo deve combinar duas virtudes:

- ser acurado: $v \rightarrow 0$;
- ser preciso: $\text{Var}\{Y\} \rightarrow 0$.

Capítulo 8

A difusão de um ponto de vista probabilístico

8.1 Um passeio aleatório

Na figura 8.1, uma partícula move-se a partir da origem (com certeza) em passos de tempo n , dando “saltos” de 1 unidade a cada tempo. A posição da partícula no tempo n é $X(n)$. A *probabilidade* de a partícula estar na posição k no instante n é

$$p_k(n) \equiv P\{X(n) = k\}. \quad (8.1)$$

Suponha que uma transição para cima ou para baixo seja igualmente provável, e *independente* do estado atual $X(n)$:

$$P\{X(n+1) = X(n) + 1\} = 1/2, \quad (8.2)$$

$$P\{X(n+1) = X(n) - 1\} = 1/2. \quad (8.3)$$

Então o estado k só pode ser alcançado a partir de $k+1$ ou de $k-1$, e

$$p_k(n+1) = \frac{1}{2}p_{k+1}(n) + \frac{1}{2}p_{k-1}(n). \quad (8.4)$$

Para prosseguirmos, nós vamos necessitar de derivadas numéricas. Veja a figura 8.2: as derivadas numéricas *centradas* em $x = (i+1/2)\Delta x$, e $x = (i-1/2)\Delta x$ são

$$f'_{i+1/2} \approx \frac{f_{i+1} - f_i}{\Delta x}, \quad (8.5)$$

$$f'_{i-1/2} \approx \frac{f_i - f_{i-1}}{\Delta x}. \quad (8.6)$$

A derivada numérica é o coeficiente angular da secante entre 2 pontos; a derivada *exata* é o coeficiente angular da tangente geométrica. Na figura 8.2, ambas são mostradas: se você possuir uma vista suficientemente boa, procure identificar visualmente a diferença entre elas.




Figura 8.1: Um passeio aleatório simples, começando sempre em $X = 0$.




Figura 8.2: Derivadas numéricas de ordem 1 e 2.

A derivada segunda é a derivada da derivada:

$$\begin{aligned}
 f_i'' &\approx \frac{f'_{i+1/2} - f'_{i-1/2}}{\Delta x} \\
 &= \frac{\frac{f_{i+1} - f_i}{\Delta x} - \frac{f_i - f_{i-1}}{\Delta x}}{\Delta x} \\
 &= \frac{f_{i+1} - 2f_i + f_{i-1}}{\Delta x^2}.
 \end{aligned} \tag{8.7}$$

Com isto, nós podemos agora manipular a equação (8.4):

$$\begin{aligned}
 p_k(n+1) &= \frac{1}{2} (p_{k+1}(n) + p_{k-1}(n)) \\
 2p_k(n+1) &= p_{k+1}(n) + p_{k-1}(n) \\
 2(p_k(n+1) - p_k(n)) &= p_{k+1}(n) - 2p_k(n) + p_{k-1}(n) \\
 \frac{p_k(n+1) - p_k(n)}{\Delta x^2} &= \frac{1}{2} \frac{p_{k+1}(n) - 2p_k(n) + p_{k-1}(n)}{\Delta x^2} \\
 \frac{p_k(n+1) - p_k(n)}{\Delta t} &= \frac{\Delta x^2}{2\Delta t} \frac{p_{k+1}(n) - 2p_k(n) + p_{k-1}(n)}{\Delta x^2}
 \end{aligned} \tag{8.8}$$

Faça agora

$$p_k(n) = p(k\Delta x, n\Delta t) = p(x, t)$$

e mantenha

$$\mathcal{D} = \frac{\Delta x^2}{2\Delta t} \tag{8.9}$$

constante, enquanto $\Delta x \rightarrow 0$. (8.8) torna-se

$$\begin{aligned}
 \frac{p(x, t + \Delta t) - p(x, t)}{\Delta t} &= \mathcal{D} \frac{p(x + \Delta x, t) - 2p(x, t) + p(x - \Delta x, t)}{\Delta x^2} \rightarrow \\
 \frac{\partial p}{\partial t} &= \mathcal{D} \frac{\partial^2 p}{\partial x^2}.
 \end{aligned} \tag{8.10}$$

Esta é a mesma equação de difusão que nós resolvemos no capítulo ??! Isto significa que nós podemos dar à concentração de uma substância uma interpretação *probabilística*: ela é (também) a probabilidade de encontrarmos em (x, t) uma partícula emitida em uma certa posição (digamos, ξ) no instante $t = 0$. Mas será $\mathcal{D} = \Delta x^2/(2\Delta t)$ realmente constante? Esta pergunta possui uma resposta *estatística*, encontrada por Albert Einstein em 1905

8.2 A solução de Einstein para o movimento Browniano

Suponha que existem partículas movendo-se aleatoriamente dentro de um fluido de viscosidade dinâmica μ e com temperatura termodinâmica T . A força de resistência ao movimento de uma partícula é dada pela lei de Stokes:

$$F_R = -6\pi\mu a \frac{dX}{dt}, \tag{8.11}$$

onde X é a posição aleatória da partícula, e a é o seu raio. Em (8.11), note que X é um escalar: nossa abordagem aqui será *unidimensional*, porque isto é mais fácil algebricamente. Quando fazemos isto, perdemos um pouco do realismo da situação, e muitas pessoas têm dificuldade em raciocinar com situações que, embora matematicamente mais simples, não possuem uma representação concreta no mundo real. Entretanto, esta é uma *excelente* maneira de abordar aquele mundo real: aos poucos, introduzindo as dificuldades matemáticas apenas quando não é mais possível escamoteá-las.

As velocidades das partículas, V , dependem da temperatura do fluido (e delas mesmas), segundo a Mecânica Estatística, via

$$\left\langle \frac{mV^2}{2} \right\rangle = \frac{1}{2}kT, \quad (8.12)$$

onde k é a constante de Boltzmann.

Além de F_R , as partículas sofrem a ação de forças aleatórias F , que são produzidas pelos choques com as moléculas do fluido. A equação de movimento (unidimensional, é claro) de um partícula é

$$m \frac{d^2 X}{dt^2} = -6\pi\mu a \frac{dX}{dt} + F. \quad (8.13)$$

Volte agora ao coeficiente de difusão dado por (8.9): se partirmos de $x = 0$, $t = 0$, teremos (para cada partícula)

$$X^2 = 2\mathcal{D}t.$$

Suponha que esta relação seja válida na média de todas as partículas; então,

$$\langle X^2 \rangle = 2\mathcal{D}t, \quad (8.14)$$

$$\frac{d}{dt} \langle X^2 \rangle = 2\mathcal{D}, \quad (8.15)$$

$$\frac{d^2}{dt^2} \langle X^2 \rangle = 0. \quad (8.16)$$

Lembre-se de que por enquanto (8.14) é apenas uma suposição, que nós devemos ser capazes de provar. Agora,

$$\frac{d}{dt} \langle X^2 \rangle = \left\langle \frac{d}{dt} X^2 \right\rangle = \left\langle 2X \frac{dX}{dt} \right\rangle, \quad (8.17)$$

$$\frac{d^2}{dt^2} \langle X^2 \rangle = 2 \left[\left\langle \frac{dX}{dt} \right\rangle^2 + \left\langle X \frac{d^2 X}{dt^2} \right\rangle \right]. \quad (8.18)$$

Invocando agora (8.16) (que ainda é apenas uma hipótese que precisa ser provada),

$$\left\langle X \frac{d^2 X}{dt^2} \right\rangle = - \left\langle \frac{dX}{dt} \right\rangle^2. \quad (8.19)$$

A equação (8.19) será útil em (8.13); multiplicando esta última por X e utilizando (8.19):

$$\begin{aligned} m \left\langle X \frac{d^2 X}{dt^2} \right\rangle &= -6\pi a \mu \left\langle X \frac{dX}{dt} \right\rangle + \langle XF \rangle, \\ -m \left\langle \frac{dX}{dt} \right\rangle^2 &= -6\pi a \mu \left\langle X \frac{dX}{dt} \right\rangle + \langle XF \rangle. \end{aligned} \quad (8.20)$$

Raciocine agora probabilisticamente: X é a posição de uma partícula qualquer, com $\langle X \rangle = 0$. F é a força aleatória sobre uma partícula, com $\langle F \rangle = 0$. X e F *devem* ser variáveis aleatórias independentes:

$$\text{Cov}\{X, F\} = \langle (X - \langle X \rangle)(F - \langle F \rangle) \rangle = \langle XF \rangle = 0. \quad (8.21)$$

Segue-se que

$$\begin{aligned} 6\pi a\mu \left\langle X \frac{dX}{dt} \right\rangle &= m \left\langle \frac{dX^2}{dt} \right\rangle = kT, \\ 6\pi a\mu \left\langle 2X \frac{dX}{dt} \right\rangle &= 2kT, \\ 6\pi a\mu \frac{d}{dt} \langle X^2 \rangle &= 2kT, \\ \frac{d}{dt} \langle X^2 \rangle &= \frac{kT}{3\pi a\mu} = 2\mathcal{D}, \end{aligned} \quad (8.22)$$

$$\mathcal{D} = \frac{kT}{6\pi a\mu}. \quad (8.23)$$

Observe que (8.22) é a mesma que (8.15): a hipótese (8.14) é *consistente* com o resultado que obtivemos, e o justifica *a posteriori*.

A relação entre k , o número de Avogadro N_A , e a constante universal dos gases pode ser encontrada nos bons livros do ramo: $R = kN_A$, ou seja:

$$\frac{d}{dt} \langle X^2 \rangle = \frac{RT}{3\pi a\mu N_A}; \quad (8.24)$$

esta é uma forma de determinar experimentalmente o número de Avogadro 🚧**You should re-read Abraham Pais!**

Uma maneira mais formal de deduzir que $\frac{d^2}{dt^2} \langle X^2 \rangle = 0$ é a seguinte. Suponha que X seja um processo estocástico com incrementos estacionários:

$$\begin{aligned} \frac{d}{dt} \langle (X(t) - X(s))^2 \rangle &= 0, \quad \forall t, s, \ t > s, \\ \frac{d}{dt} \left\langle \frac{(X(t) - X(s))^2}{t - s} \right\rangle &= 0, \\ \frac{d}{dt} \left\langle \frac{(\Delta X)^2}{\Delta t} \right\rangle &= 0, \\ \left\langle \frac{(\Delta X)^2}{\Delta t} \right\rangle &= 2\mathcal{D}. \end{aligned} \quad (8.25)$$

Como vimos, a distribuição de probabilidade da posição de uma partícula no passeio aleatório descrito na seção 8.1 possui equação governante (8.10), com

$$p(x, 0) = \delta(x), \quad (8.26)$$

$$\int_{-\infty}^{+\infty} p(x, t) dx = 1, \quad \forall t. \quad (8.27)$$

É fácil interpretar estas duas últimas equações. (8.26) nos informa que $X(0) = 0$ com probabilidade 1: a partícula *sempre* sai de $x = 0$. (8.27) requer que a densidade de probabilidade possua integral unitária, o que é óbvio. Note que (8.10) juntamente com as condições (8.26)–(8.27) é um problema clássico *que nós já resolvemos*, utilizando transformada de Fourier. A solução que obtivemos é

$$p(x, t) = \frac{1}{\sqrt{4\pi Dt}} \exp \left[-\frac{x^2}{4Dt} \right]. \quad (8.28)$$

Se fizermos, de acordo com a teoria do movimento Browniano de Einstein da seção 8.2

$$\sigma^2 \equiv \langle X^2 \rangle = 2Dt \quad (8.29)$$

e substituirmos em (8.28), teremos

$$p(x, t) = \frac{1}{\sqrt{2\pi\sigma}} \exp \left[-\frac{1}{2} \left(\frac{x}{\sigma} \right)^2 \right]. \quad (8.30)$$

Esta é uma velha conhecida nossa: trata-se da distribuição normal, ou gaussiana, de probabilidade. Neste contexto, o *desvio-padrão* da posição da partícula, σ , cresce com a raiz quadrada do tempo t .

Equações do tipo (8.29) aparecem com frequência em problemas de difusão, e seu surgimento agora deve estar mais claro para você.

8.3 Uma introdução informal a processos estocásticos

Primeiro, alguns exemplos: as condições de tempo (tempo bom — sol, ou tempo ruim — chuva), o total de milímetros de chuva precipitados a cada 24 horas, e a vazão em um rio a cada dia, são todos exemplos de fenômenos que podem ser *modelados* como processos estocásticos.

Note o cuidado com as palavras: estes fenômenos podem ser *modelados* como processos estocásticos; eles não *são* processos estocásticos. Tanto quanto sabemos, a natureza não “sabe” o que ela mesma é; somos nós que lhe atribuímos certas propriedades, e a “enfeitamos” com hipóteses e modelos.

De fato, é totalmente irrelevante o que a natureza realmente “é”: tudo o que devemos nos perguntar é se os modelos que utilizamos são uma boa descrição daqueles aspectos da natureza que consideramos importante modelar, para efeito de compreensão e de previsão

De volta aos fenômenos que identificamos como passíveis de serem modelados como processos estocásticos, observe que

1. O tempo amanhã é muito parecido com o tempo hoje: se hoje o tempo está bom, é grande a chance de o tempo também estar bom amanhã. Uma boa variável para testar isto é a pressão atmosférica.
2. Uma coisa semelhante acontece — não por coincidência, é claro — com a chuva: se hoje está chovendo, é grande a chance de ainda estar chovendo amanhã.




Figura 8.3: Ilustração de um processo estocástico.

3. Idem para a vazão de um rio — de novo você deve notar que estes 3 fenômenos estão intimamente ligados — se hoje a vazão de um rio está baixa (porque não chove na bacia há muitos dias), então é grande a chance de que ela continue baixa amanhã.

Por outro lado, a relação entre o tempo (ou a chuva, ou a vazão) hoje e daqui a 3 meses é praticamente nula: a persistência destes fenômenos não dura — normalmente — mais do alguns dias. Figurativamente, depois de um certo número de dias a natureza “se esquece” de si mesma. A idéia aqui é que muitos fenômenos possuem uma memória “finita”. Nosso trabalho agora é obter uma caracterização matemática razoável do que são processos estocásticos, e do que é a sua “memória”.

Definição — Um processo estocástico $X(t, \omega)$ é uma função que leva cada $\omega \in \Omega$ de um *espaço amostral* em uma função $x(t) = X(t, \omega)$.

Uma figura vale mais do que mil palavras. A figura 8.3 ilustra a definição de processo estocástico. Nesta figura, 3 valores diferentes de ω geram 3 funções $x(t)$ distintas. Mas não se engane! A *estocasticidade* — isto é, a aleatoriedade — do processo está no sorteio dos ω 's, e não na aparência “aleatória” de $x(t)$! De fato, cada um dos 3 gráficos de $X(t, \omega)$ na figura 8.3 poderia ser uma função perfeitamente suave, e ainda assim o “processo” seria estocástico. A aparência de aleatoriedade de cada um dos gráficos está ligada a

propriedades *adicionais* — e muito úteis na prática — de alguns processos estocásticos. Estas propriedades são a memória finita, e a ergodicidade. Nós agora passamos a descrevê-las.

Definição — A função de autocovariância de um processo estocástico $X(t)$ é

$$C(r, s) \equiv \langle (X(r) - \langle X(r) \rangle)(X(s) - \langle X(s) \rangle) \rangle \quad (8.31)$$

Quando $X(t)$ é estacionário, (8.31) simplifica-se consideravelmente. Em processos estacionários, estatísticas calculadas em um instante t qualquer não dependem do mesmo. Então,

$$\langle X(r) \rangle = \langle X(s) \rangle = \mu_X, \quad (8.32)$$

$$\langle (X(t) - \mu_X)^2 \rangle = \sigma_X^2, \quad (8.33)$$

sendo que μ_X e σ_X^2 são *constantes* ao longo do tempo.

Em segundo lugar, se $X(t)$ é estacionário, estatísticas que dependem de *mais de um instante* permanecem inalteradas sob uma translação no tempo. Então,

$$C(r, s) = C(r - s, 0). \quad (8.34)$$

Em outras palavras, *a função de autocovariância de um processo estocástico estacionário depende apenas da diferença entre os instantes r e s* . Isto nos dá, agora, uma definição mais simples (porém também mais restrita, porque só vale para processos estocásticos estacionários) para a função de autocovariância:

$$C(\tau) = \langle (X(t) - \mu_X)(X(t + \tau) - \mu_X) \rangle. \quad (8.35)$$

Com $C(\tau)$ é possível definir uma

Vamos seguir agora para uma introdução informal à Teoria de Difusão Turbulenta de Taylor. Não custa repetir, nossa versão é unidimensional (e portanto demasiadamente simplificada para algumas aplicações).

Vamos agora começar a descrição de uma outra teoria de difusão, que deve muito à de Einstein, e que tentar analisar a difusão turbulenta sob um ponto de vista lagrangeano, ou seja: sob o ponto de vista do passeio aleatório de uma partícula em um fluido em escoamento turbulento.

Da mesma maneira que na seção 8.2, nós vamos estudar o problema em uma dimensão, para simplificar a matemática.

Em primeiro lugar, note que a posição X de uma partícula no instante t pode ser interpretada como uma soma de incrementos, como se segue:

$$X(t) = \int_0^t U(\tau) d\tau = \lim_{\Delta\tau \rightarrow 0} \sum_k U(\tau_k) \Delta\tau.$$

Em (8.36), U é a velocidade da partícula em cada instante, e a integral foi re-interpretada como (o limite de) uma soma de Riemman. É muito razoável agora supor que todos os

$U(\tau_k)$'s são indenticamente distribuídos, e invocar o Teorema Central do Limite. Nós concluimos então, imediatamente, que X é distribuído normalmente.

Nosso ponto de partida — que já foi dado — é a integral (8.36). Vamos supor que o campo de velocidade U que transporta a partícula possui média zero: $\langle U \rangle = 0$. Segue-se de (8.36) que

$$\langle X(t) \rangle = \left\langle \int_0^t U(\tau) d\tau \right\rangle = \int_0^t \langle U(\tau) \rangle d\tau = 0. \quad (8.36)$$

A função de autocovariância simplifica-se ainda mais:

$$C(\tau) = \langle X(t)X(t+\tau) \rangle.$$

Projeto 8.1 Um processo estocástico “clássico” é o modelo AR-2 dado por

$$X_n = a_1 X_{n-1} + a_2 X_{n-2} + E \quad (8.37)$$

onde E é um ruído branco de média zero e variância σ^2 . Os parâmetros a_1 e a_2 devem obedecer a (Bras e Rodríguez-Iturbe, 1993, eq. 2.54):

$$\begin{aligned} a_1 + a_2 &< 1, \\ a_2 - a_1 &< 1, \\ -1 &< a_2 < 1. \end{aligned}$$

Por exemplo, podemos ter $a_1 = 0,8$, e $a_2 = -0,2$.

Referências Bibliográficas

- Birkhoff, G. D. (1931). Proof of the Ergodic Theorem. *Proceedings of the National Academy of Sciences*, 17(12):656–660.
- Bras, R. L. e Rodríguez-Iturbe, I. (1993). *Random functions and hydrology*. Dover, New York.
- Butkov, E. (1988). *Física matemática*. Guanabara Koogan, Rio de Janeiro.
- Collet, P. (2010). *Dynamical Systems and Stochastic Processes*.
- Dias, N. L. (2003). Obtenção de uma solução analítica da equação de difusão-advecção com decaimento de 1^a ordem pelo método da transformação de similaridade generalizada. *Revista Brasileira de Recursos Hídricos*, 8:181–188.
- Dias, N. L., Gobbi, M. F., e Gobbi, E. F. (2003). Formulação de um modelo matemático do efeito de efluentes térmicos em rios e suas implicações para a legislação ambiental brasileira. *Revista Brasileira de Recursos Hídricos*, 8:169–180.
- Einstein, A. (1905). Über die von der molekularkinetischen Theorie der Wärme geforderte Bewegung von in ruhenden Flüssigkeiten suspendierten Teilchen. *Annalen der Physik*, 322(8):549–560.
- Hinze, J. O. (1975). *Turbulence*. McGraw-Hill Publishing Company, New York.
- Kolmogorov, A. N. (1933). *Grundbegriffe der Wahrscheinlichkeitsrechnung (Foundations of the theory of probability)*. Springer, Berlin.
- Kolmogorov, A. N. (1941). The local structure of turbulence in incompressible viscous fluid for very large Reynolds numbers (Russian). *Proceedings of the USSR Academy of Sciences*, 30(299–303).
- Kundu, P. K. (1990). *Fluid Mechanics*. Academic Press, San Diego.
- Langevin, P. (1908). Sur la théorie du mouvement brownien. *C. R. Acad. Sci. (Paris)*, 146:530–533.
- Lebowitz, J. L. e Penrose, O. (1973). Modern ergodic theory. *Physics Today*, 26(2):23–29.
- Maxwell, J. C. (1867). On the Dynamical Theory of Gases. *Philosophical Transactions of the Royal Society of London*, 157:pp. 49–88.

- Monin, A. S. e Yaglom, A. M. (1975). *Statistical fluid mechanics: Mechanics of turbulence*, volume 2. MIT Press, Cambridge, Massachusetts.
- Pope, S. B. (2000). *Turbulent Flows*. Cambridge University Press, Cambridge.
- Reynolds, O. (1895). On the dynamical theory of incompressible viscous fluids and the determination of the criterion. *Philos. Trans. R. Soc. Lond. A*, 186:123–164.
- Taylor, G. I. (1935a). Statistical theory of turbulence. I. *Proceedings of the Royal Society of London A*, 151:421–444.
- Taylor, G. I. (1935b). Statistical theory of turbulence. II. *Proceedings of the Royal Society of London A*, 151:444–454.
- Taylor, G. I. (1935c). Statistical theory of turbulence. III. *Proceedings of the Royal Society of London A*, 151:455–464.
- Taylor, G. I. (1935d). Statistical theory of turbulence. IV. *Proceedings of the Royal Society of London A*, 151:465–478.
- Taylor, S. J. (1973). *Introduction to measure and integration*. Cambridge University Press.
- Tennekes, H. e Lumley, J. L. (1972). *A first course in turbulence*. The MIT Press, Cambridge, Massachusetts.
- von Neumann, J. (1932). Zur Operatorenmethode In Der Klassischen Mechanik. *The Annals of Mathematics*, 33(3):587.